今天 上午9:36

在 Kaggle 上的多元線性迴歸問題，跟汽車有關的內容，是否有特徵數量大於 13 且小於 40的項目?

有，而且我查到幾個符合你條件的 Kaggle 汽車資料集。若你是要延續之前的 **Python、Scikit-learn 多元線性迴歸作業**，我會建議優先選擇「預測汽車價格」的資料集。

先釐清一個重點：你說的「特徵數量大於 13 且小於 40」，代表 **14～39 個特徵**。這裡建議以資料集原始欄位數作為初步篩選依據，但要注意，目標欄位（例如汽車價格）及 ID 欄位通常不應計入模型的輸入特徵；類別欄位經過 One-Hot Encoding 後，也可能產生更多特徵。

一、推薦的 4 個 Kaggle 汽車資料集

1. Car Features and MSRP（最推薦）

Car Features and MSRP

Kaggle 官方資料集： Cooper Union Car Features and MSRP

這份資料集包含約 11,914 筆資料、16 個欄位，適合用來研究汽車規格與價格之間的關係。 Omega Search

項目	內容
研究主題	根據汽車規格預測建議售價
資料筆數	約 11,914 筆
原始欄位數	16 個
目標變數	`MSRP`（建議售價）
推薦程度	★★★★★

主要欄位包括：

- `Make`：汽車品牌
- `Model`：車款
- `Year`：年份
- `Engine HP`：引擎馬力
- `Engine Cylinders`：汽缸數
- `Transmission Type`：變速箱類型
- `Driven_Wheels`：驅動方式
- `Vehicle Size`：車輛尺寸
- `Vehicle Style`：車身形式
- `highway MPG`：高速公路油耗
- `city mpg`：市區油耗
- `Popularity`：車款人氣指標
- `MSRP`：建議售價

為什麼推薦？

這份資料集的欄位數落在你要求的範圍，而且同時具有數值型與類別型變數，很適合練習資料清理、特徵選擇、類別編碼及模型評估。

不過，16 個原始欄位中包含目標變數 `MSRP`，因此扣除目標變數後，輸入特徵會少一個。實際使用時還需要檢查是否有其他不適合納入模型的欄位。

2. Used Car Price Prediction Challenge

Used Car Price Prediction Challenge

Kaggle 官方資料集： Used Car Price Prediction Challenge

項目	內容
研究主題	預測二手車價格
原始欄位數	約 27 個
目標變數	`price`
特徵類型	數值型、類別型及文字型
適用模型	多元線性迴歸
推薦程度	★★★★☆

這份資料集很適合用來探討二手車的價格影響因素。

但有兩個需要注意的地方：

1. 部分欄位是文字，例如 `engine`、`features_list`，需要額外處理。
2. `id`、`vin` 等欄位未必適合直接當作預測特徵。

如果是課堂作業，我會建議先排除不必要的文字欄位，挑選容易解釋的數值與類別特徵，再建立迴歸模型。

3. Car-prices

Kaggle 官方資料集： Car-prices

這是一份用於預測二手車價格的迴歸競賽資料集，資料由深度學習模型根據原始二手車價格資料生成。其訓練與測試資料合計包含不同用途的資料檔案，原始欄位數約為 27 個。 Kaggle

項目	內容
研究主題	汽車價格預測
資料特性	合成資料
推薦程度	★★★☆☆

這份資料的欄位數符合你的條件，但如果老師希望研究真實汽車交易或刊登價格，我會優先考慮前兩份。

4. Used Car Price Prediction Dataset

Kaggle 官方資料集： Used Car Price Prediction Dataset

這份資料集主要用來預測二手車價格，包含品牌、車款、年份、里程、燃料類型、引擎、變速箱、車身顏色及事故紀錄等資訊。

不過，資料集的原始欄位數約為 12 個，未達到你設定的 14～39 個，因此**不符合你的原始條件**。 Clusy

二、這幾份資料集該怎麼選？

比較項目	Car Features and MSRP	Used Car Price Prediction Challenge	Car-prices
原始欄位數	16	約 27	約 27
預測目標	新車建議售價	二手車價格	二手車價格
資料性質	汽車規格資料	真實刊登資料	合成資料
資料清理難度	中等	中高	中等
類別特徵處理	需要	需要	需要

以上欄位數是原始資料的初步比較，實際建模前仍應檢查各版本資料檔案的欄位與缺失值。

三、如果是你的多元線性迴歸作業，我會怎麼選？

我會優先選擇第一份 Car Features and MSRP，主要有三個原因：

1. **欄位數符合需求：** 原始資料有 16 個欄位，落在 14～39 個的範圍。
2. **適合比較特徵選擇方法：** 可以比較相關係數、單變量特徵選擇、遞迴特徵消除等方法，觀察哪些汽車規格對售價預測較有幫助。
3. **容易解釋實驗結果：** 例如比較引擎馬力、汽缸數、車輛尺寸與價格的關係，分析不同特徵組合對模型表現的影響。

如果你希望延續之前的作業架構，還可以進一步比較五種特徵選擇方法，並使用以下指標評估模型：

- **R^2：** 模型能解釋多少價格變異。
- **MAE：** 預測價格的平均絕對誤差。
- **RMSE：** 對較大的預測誤差給予更高懲罰。

最後提醒：這些資料集都可以用於迴歸研究，但若老師明確要求「多元線性迴歸」，就應以線性迴歸作為主要模型；其他方法可以用來選擇特徵，而不是直接把隨機森林等非線性模型當成多元線性迴歸的替代品。

我的建議是先下載第一份資料集，確認原始欄位，再決定要保留哪些特徵。 這樣最容易控制實驗範圍，也方便整理成作業報告。

這次作業內容如下，特徵選擇一樣要五種，評估：對比 MAE、MSE、RMSE、R^2 及調整後 R^2（Adjusted R^2）指標；驗證迴歸分析的五個假設。
一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。&#xA;

&#xA; 類型不限（可為房價預測、醫療、車輛效能等主題）。&#xA; 請明確標示資料集來源與連結。
2. 分析任務&#xA; 使用線性回歸 (Linear Regression) 模型進行預測。 &#xA; 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。 &#xA; 必須執行 特徵選擇 (Feature Selection) 與 模型評估 (Model Evaluation)。&#xA; 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明&#xA; Business Understanding&#xA; Data Understanding&#xA; Data Preparation&#xA; Modeling&#xA; Evaluation&#xA; Deployment

4. AI協助要求
所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須匯出為 PDF（這個部分我可以自己處理）&#xA; 請使用 NotebookLM 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。&#xA; 請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」（摘要麻煩幫我產生）

我認為可以選擇第一份 Car Features and MSRP 來當作作業的訓練資料。幫我列一下prompt，要貼到vscode的agent上面請他幫我製作，最後會上傳到github上並布署到streamlit。
另外，有以下加分要求，幫我把功能要求一併加入到prompt
加總分 1分:
1. 有下拉視窗呈現兩種problem
加總分2分
1. 可任意輸入 Dataset (such as https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv)

我建議這次直接把專案設計成一個完整的 **Streamlit 多元線性迴歸分析平台**，而不只是執行 Python 程式後顯示幾張圖。

依照老師的要求，除了以 `Car Features and MSRP` 作為預設資料集，還要加入五種特徵選擇方法、五項迴歸假設檢驗、四項基本評估指標與調整後 R^2，以及預測區間和 CRISP-DM 六階段說明。

另外，兩項加分要求也要直接納入系統設計：

- **加分 1 分：** 使用下拉式選單切換兩種 Problem。
- **加分 2 分：** 使用者可以輸入任意公開資料集的 CSV 網址，系統自動讀取資料、選擇目標變數並執行分析。

我會建議把兩種 Problem 設計成：

1. **Car Price Prediction：** 汽車價格預測，使用 Car Features and MSRP。
2. **Custom Dataset Regression：** 自訂資料集迴歸分析，使用者可輸入 CSV 網址，例如老師提供的 Startup 50 資料集。

第二種模式可以使用 `50_Startups.csv` 作為示範，預設目標變數為 `Profit`。這樣既能展示汽車主題，也能證明你的程式具有通用性。

以下是可以直接貼到 VS Code Agent（例如 GitHub Copilot Agent 或其他程式開發 Agent）的完整 Prompt。

VS Code Agent 完整開發 Prompt：多元線性迴歸分析平台

專案名稱：Multiple Linear Regression Analysis Platform

請你扮演一位熟悉 Python、資料科學、機器學習、統計分析及 Streamlit 部署的資深工程師，直接在目前開啟的 VS Code Repository 中，協助我完成一個可實際執行、具有完整分析流程、視覺化圖表與研究報告內容的「多元線性迴歸分析平台」。

本專案是大學 AIoT / 資料探勘課程的作業，必須遵循 CRISP-DM 流程，並以 scikit-learn、pandas、

Code 執行」，確認結果後上傳 GitHub，最後部署至 Streamlit Community Cloud。

所有操作介面、圖表標題、分析說明及報告內容均以繁體中文呈現，必要的英文技術名詞可以保留。

一、作業目標與核心要求

完成一個可以切換不同 Problem 的多元線性迴歸分析平台。

必須具備以下功能：

1. 兩種 Problem 的下拉式選單。
2. 預設汽車價格預測資料集。
3. 使用者可輸入公開 CSV 網址，自訂資料集。
4. 自動進行資料理解、資料清理與前處理。
5. 提供五種特徵選擇方法。
6. 使用 Multiple Linear Regression 建立預測模型。
7. 比較 MAE、MSE、RMSE、R^2、Adjusted R^2 五項評估指標。
8. 驗證迴歸分析的五個假設。
9. 顯示實際值與預測值比較圖。
10. 顯示具有 95% 預測區間的預測圖。
11. 提供完整的 CRISP-DM 六階段說明。
12. 提供「GPT 輔助內容」與「NotebookLM 摘要」。
13. 支援下載分析結果、指標比較表及圖表。
14. 專案可以直接部署到 Streamlit Community Cloud。

請特別注意：老師要求的是多元線性迴歸，不要將隨機森林、XGBoost 或其他非線性模型當成主要模型。

二、Problem 下拉式選單

- Problem 1：汽車價格預測（Car Prediction）
- Problem 2：自訂資料集迴歸分析（Custom Dataset Regression）

使用者切換 Problem 時，應更新對應的資料集、設定、圖表與分析結果。

Problem 1：汽車價格預測

使用 Kaggle 公開資料集：

資料集名稱：Car Features and MSRP

Kaggle 資料集識別名稱：CooperUnion/cardataset

官方資料集頁面：
https://www.kaggle.com/datasets/CooperUnion/cardataset

資料內容包含汽車品牌、車款、年份、引擎馬力、汽缸數、變速箱、驅動方式、油耗、車輛尺寸及建議售價等資訊。

預測目標：

MSRP，也就是汽車建議售價。

請優先使用公開且可取得的 CSV 原始資料網址讀取資料，不要要求使用者提供 Kaggle API Token。

如果無法直接讀取 Kaggle 網頁或 CSV，請顯示清楚的錯誤訊息，並提供以下替代方式：

1. 使用者自行下載 CSV 並上傳。
2. 使用者輸入其他可公開讀取的 CSV 網址。
3. 提供必要的資料集取得說明。

不得假裝已成功讀取資料，也不得在無法取得資料時產生虛構的模型評估數據。

如果原始資料實際欄位數與預期不同，請以實際讀取結果為準，並顯示資料筆數、原始欄位數、目標變

提供三種資料來源：

1. 輸入公開 CSV URL。
2. 上傳本機 CSV 檔案。
3. 使用內建的 Startup 50 範例資料集。

Startup 50 範例資料集：

https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv

預設目標變數為 Profit。

這個模式必須具備通用性，不能只針對 Startup 50 寫死程式。

使用者輸入其他符合條件的 CSV URL 時，程式必須嘗試讀取該資料集，並根據資料內容提供可選擇的目標變數與特徵欄位。

自訂資料集處理規則

- 自動偵測數值型與類別型欄位。
- 讓使用者選擇目標變數。
- 讓使用者選擇要納入分析的特徵。
- 排除目標變數本身。
- 預設排除明顯不適合作為預測特徵的 ID 欄位。
- 允許使用者手動調整排除欄位。
- 顯示原始資料的前五筆、欄位型態、缺失值及基本統計。
- 自動處理合理範圍內的資料問題。
- 若資料無法用於迴歸分析，應說明原因及改善方法。

請注意：本作業主要針對數值型連續目標變數。如果目標欄位是文字、類別或無法轉換為數值的資料，請要求使用者重新選擇目標欄位，而不是直接執行錯誤的迴歸分析。

三、CRISP-DM 六階段分析流程

網站必須清楚呈現完整的 CRISP-DM 流程。

建議使用六個頁籤或六個可展開區塊。

1. Business Understanding（商業理解）

汽車資料集的研究問題：

「能否利用汽車的基本規格與性能資訊，建立多元線性迴歸模型，預測汽車的建議售價？」

請說明：

- 研究目的。
- 預測目標。
- 模型的實際應用價值。
- 可能影響汽車價格的特徵。
- 本研究的限制。

自訂資料集模式則根據使用者選擇的目標變數與資料集，動態產生相對應的研究問題。

2. Data Understanding（資料理解）

至少呈現：

- 資料來源及連結。
- 資料筆數。
- 原始欄位數。
- 實際使用的輸入特徵數。
- 目標變數。
- 描述性統計。
- 數值欄位的相關係數矩陣。
- 目標變數的分布圖。
- 重要數值特徵的分布圖。

使用者應能在網頁中直接查看資料分析結果。

3. Data Preparation（資料準備）

至少包含：

- 移除重複資料。
- 處理缺失值。
- 處理無法轉換的數值。
- 數值型特徵的缺失值填補。
- 類別型特徵的缺失值填補。
- 類別特徵 One-Hot Encoding。
- 必要時處理高基數類別欄位。
- 移除無法使用的欄位。
- 特徵選擇。
- 訓練集與測試集切分。

預設採用 80% 訓練集與 20% 測試集，並固定 random_state，以確保實驗可以重現。

所有需要從資料中學習的前處理步驟，都必須透過 Pipeline 或其他正確方式，避免在訓練與測試資料之間發生資料洩漏。

特徵選擇也必須在訓練資料內進行，不能先利用全部資料選擇特徵，再進行訓練與測試切分。

4. Modeling（建模）

使用 sklearn.linear_model.LinearRegression 建立多元線性迴歸模型。

五種方法的詳細要求請參照下一節。

5. Evaluation（評估）

顯示：

- MAE。
- MSE。
- RMSE。
- R^2。
- Adjusted R^2。
- 實際值與預測值比較。
- 預測區間。
- 迴歸假設檢驗。
- 五種特徵選擇方法的結果比較。

請針對結果提供繁體中文解釋，不要只呈現數字。

6. Deployment（部署）

網站內說明本模型如何實際應用，以及目前的限制。

例如：

- 使用者輸入汽車規格。
- 模型產生預測售價。
- 顯示預測區間。
- 說明預測結果不代表實際成交價格。
- 說明模型只適用於與訓練資料特性相近的資料。

若提供單筆汽車價格預測功能，必須使用訓練時相同的資料前處理與模型 Pipeline。

如果模型包含 One-Hot Encoding，單筆預測也必須沿用相同的欄位處理規則。

本作業必須提供五種不同的特徵選擇方法，且每一種方法都必須實際執行，不能只有文字介紹。

請使用以下五種方法。

方法 1：Pearson Correlation（皮爾森相關係數）

計算數值型特徵與目標變數之間的 Pearson 相關係數。

以相關係數絕對值作為初步排序依據。

要求：

- 顯示各特徵的相關係數。
- 以長條圖呈現。
- 顯示選出的特徵。
- 說明相關係數不代表因果關係。
- 類別特徵必須透過適當的數值轉換才能進入後續模型，不能直接將任意類別編碼當作具有線性意義的數值。

對於數值型特徵的相關係數排名，應在訓練資料中計算。

方法 2：SelectKBest + f_regression

使用：

sklearn.feature_selection.SelectKBest

搭配：

sklearn.feature_selection.f_regression

讓使用者設定選擇的特徵數量 K。

- 顯示各特徵的 F-score。
- 顯示選出的特徵。
- 以圖表呈現特徵分數。
- 確保特徵選擇只使用訓練資料。

方法 3：Recursive Feature Elimination（RFE）

使用：

sklearn.feature_selection.RFE

搭配：

LinearRegression

讓使用者設定希望保留的特徵數量。

要求：

- 顯示特徵排名。
- 顯示最終保留的特徵。
- 呈現特徵排名圖。
- 正確處理 One-Hot Encoding 後的特徵。
- 在適當的 Pipeline 架構中執行。

方法 4：Sequential Feature Selection（SFS）

使用：

sklearn.feature_selection.SequentialFeatureSelector

搭配：

要求：

- 顯示選擇的特徵。
- 顯示選擇數量。
- 說明方法如何逐步加入或移除特徵。
- 以交叉驗證或訓練資料內部的評估選擇特徵。
- 必須避免使用測試集決定最終特徵組合。

如果資料集特徵數量較多，請合理設定運算方式，避免網站執行時間過長。

方法 5：Lasso Regression（L1 正則化特徵選擇）

使用：

sklearn.linear_model.LassoCV

在訓練資料中尋找適當的正則化參數，並依據非零係數選擇特徵。

要求：

- 顯示各特徵係數。
- 顯示非零係數的特徵。
- 呈現係數長條圖。
- 解釋 L1 正則化如何讓部分係數縮小至零。
- 使用適當的特徵縮放方式。
- 特徵縮放與參數選擇不得使用測試集資訊。

注意：LassoCV 在這個專案中是用來選擇特徵，最終比較的主要預測模型仍然是一般的 LinearRegression。

五、五種特徵選擇方法的公平比較

1. 使用同一份資料。
2. 使用相同的 train/test split。
3. 使用相同的目標變數。
4. 使用相同的測試資料。
5. 使用相同的主要資料前處理規則。
6. 以各方法選出的特徵訓練 LinearRegression。
7. 只在訓練資料中進行特徵選擇。
8. 不得使用測試集挑選特徵或調整參數。
9. 必須記錄每種方法實際選出的特徵。
10. 必須記錄每種方法使用的有效特徵數。

請製作比較表格，欄位至少包含：

特徵選擇方法	特徵數量	MAE	MSE	RMSE	R^2	Adjusted R^2

所有指標都必須由實際執行模型計算，不得預先填入虛構數字。

比較結果需提供排序功能，預設以測試集 RMSE 由低至高排列。

同時顯示五種方法的：

- MAE 比較圖。
- MSE 比較圖。
- RMSE 比較圖。
- R^2 比較圖。
- Adjusted R^2 比較圖。

建議使用 Matplotlib 或 Seaborn，確保圖表標題、軸標籤及圖例皆清楚易讀。

六、模型評估指標

Mean Absolute Error，平均絕對誤差。

說明預測值與實際值之間的平均絕對差距。

越低通常越好。

2. MSE

Mean Squared Error，均方誤差。

對較大的預測誤差給予更高權重。

越低通常越好。

3. RMSE

Root Mean Squared Error，均方根誤差。

其單位與目標變數相同。

越低通常越好。

4. R²

Coefficient of Determination，決定係數。

說明模型在測試資料上對目標變數變異的解釋程度。

R² 可能小於零，不應強制限制為 0 ~ 1。

5. Adjusted R²

Adjusted Coefficient of Determination，調整後決定係數。

n > p + 1

時，使用：

Adjusted R² = 1 - (1 - R²) × (n - 1) / (n - p - 1)

注意：

- p 不包含截距項。
- 對 One-Hot Encoding 後的模型，應使用實際進入最終模型的有效設計矩陣欄位數。
- 不能直接將原始欄位數當成 p。
- 若 n ≤ p + 1，應顯示無法可靠計算或不適用，不要產生誤導性數值。
- 必須說明 R² 與 Adjusted R² 的差異。

請使用實際測試集預測結果計算 MAE、MSE、RMSE 及 R²。

Adjusted R² 也應依照相同測試集的 R² 與實際有效特徵數計算，並清楚標示其計算方式。

七、驗證迴歸分析的五個假設

請新增獨立的「迴歸假設檢驗」區塊。

本專案採用以下五項假設：

1. 線性關係（Linearity）。
2. 誤差獨立性（Independence of Errors）。
3. 誤差等變異性（Homoscedasticity）。
4. 殘差常態性（Normality of Residuals）。
5. 無嚴重多重共線性（No Severe Multicollinearity）。

請逐項提供圖表、統計檢定及繁體中文解釋。

提供：

- Residuals vs Fitted Plot。
- 必要時提供部分殘差或其他輔助視覺化。
- 說明殘差是否圍繞零值隨機分布。
- 討論是否存在彎曲趨勢或其他非線性模式。

不要只依賴 Pearson 相關係數，就宣稱所有變數與目標變數都符合線性假設。

假設 2：誤差獨立性

提供 Durbin-Watson 統計量。

使用 statsmodels 的相關功能計算，並解釋統計量接近 2 通常代表較少的一階殘差自相關證據。

注意：

- Durbin-Watson 主要用於檢查特定形式的殘差自相關。
- 對一般橫斷面汽車資料，不可僅依賴 Durbin-Watson 就宣稱誤差完全獨立。
- 若資料有時間或順序資訊，應提醒使用者檢查資料排序與依賴結構。
- 若資料不具合理順序，應明確說明此檢定的限制。

假設 3：誤差等變異性

提供：

- Scale-Location Plot 或其他適合的殘差圖。
- Breusch-Pagan Test。

顯示：

- LM 統計量。
- p-value。

若 p-value < 0.05，應說明有證據顯示殘差變異數可能不固定。

不能只根據單一統計檢定就認定模型一定存在或不存在所有異質變異問題。

假設 4：殘差常態性

提供：

- Residual Histogram。
- Q-Q Plot。
- Shapiro-Wilk Test。

若樣本量太大，Shapiro-Wilk 可能對輕微偏離非常敏感，請在報告中提醒使用者同時觀察 Q-Q Plot。

顯示：

- W 統計量。
- p-value。
- alpha = 0.05。
- 是否有足夠證據拒絕殘差常態性的虛無假設。

若樣本量超出檢定套件的適用限制，請使用適當替代方法或清楚說明限制，不得讓程式中斷。

假設 5：無嚴重多重共線性

使用 Variance Inflation Factor（VIF）評估特徵間的多重共線性。

提供：

- 各特徵的 VIF。
- VIF 長條圖。
- 特徵共線性解釋。

請正確處理截距項及冗餘欄位，避免 VIF 計算出錯。

若存在無法計算的 VIF，應顯示原因，而不是直接忽略錯誤。

假設檢驗總表

請在網頁呈現：

假設	檢查方法	結果	判斷	說明

請注意，統計檢定的 p-value 不是「假設成立的機率」。

如果證據不足以拒絕某個假設，應使用「未發現足夠證據拒絕該假設」等準確描述，不可直接宣稱假設已被證明成立。

八、預測圖與 95% 預測區間

老師明確要求結果部分提供預測圖，並加入信賴區間或預測區間。

本專案請提供 95% 預測區間（Prediction Interval）。

至少包含以下圖表。

圖表 1：Actual vs Predicted

- X 軸：實際值。
- Y 軸：預測值。
- 加入 y = x 參考線。
- 顯示模型預測與實際結果的差異。
- 加入適當的圖例及標題。

顯示：

- 實際觀測值。
- 模型預測值。
- 95% 預測區間上下界。

若使用單一數值型特徵繪製連續預測曲線，可以將其他特徵固定在合理的參考值，並在圖表中說明設定方式。

如果模型使用多個特徵，不能直接將一條一維迴歸線當成完整的多元迴歸模型。

預測區間的統計正確性

必須注意：

- 信賴區間描述平均反應的估計不確定性。
- 預測區間描述個別新觀測值的不確定性。
- 預測區間通常比平均反應的信賴區間寬。

請不要直接將 sklearn 預測結果上下加減固定百分比，冒充 95% 預測區間。

如果需要使用 statsmodels OLS 的 get_prediction().summary_frame()，必須確保預測資料使用與訓練資料一致的特徵轉換方式。

如果無法可靠計算預測區間，請清楚說明原因，不要繪製不具統計依據的區間。

圖表 3：殘差分析

提供：

- Residuals vs Fitted。
- Residual Histogram。
- Q-Q Plot。

九、網站介面與視覺化

請使用 Streamlit 建立現代、整潔且適合課堂報告展示的網站。

建議風格：

- 深藍色或中性色系。
- 清楚的標題階層。
- 合理的卡片與區塊配置。
- 支援桌面瀏覽器。
- 重要指標使用 st.metric。
- 使用表格呈現模型比較結果。
- 圖表需有標題、軸標籤及單位。
- 所有介面使用繁體中文。

側邊欄可以包含：

1. Problem 選擇。
2. 資料來源設定。
3. 目標變數。
4. 特徵選擇設定。
5. 測試集比例。
6. Random State。
7. 交叉驗證設定。
8. 執行分析按鈕。

主畫面建議包含：

- 專案介紹。
- 資料集資訊。
- CRISP-DM 流程。
- 迴歸假設檢驗。
- 預測區間。
- AI 協助內容。
- 報告與結果下載。

請避免把所有程式都寫在同一個 app.py 裡。

請依照合理的模組化方式拆分程式，讓後續維護容易。

十、NotebookLM 摘要與 GPT 輔助內容

老師要求在報告中明確標示：

1. GPT 輔助內容。
2. NotebookLM 摘要。

請在網站建立獨立的「AI 輔助與研究摘要」區塊。

GPT 輔助內容

請列出本專案中 GPT 協助的工作，例如：

- Python 程式架構規劃。
- 多元線性迴歸模型實作。
- 五種特徵選擇方法的實作。
- 模型評估指標的計算。
- 迴歸假設檢驗的設計。
- 視覺化與報告架構。
- CRISP-DM 流程整理。
- Streamlit 網站開發與部署規劃。

請在網站中建立一個至少 100 個中文字的摘要區塊，主題為：

「利用多元線性迴歸進行汽車價格預測、特徵選擇與模型診斷」。

摘要可涵蓋：

- 汽車價格預測的研究目的。
- 資料前處理的重要性。
- 不同特徵選擇方法的差異。
- MAE、MSE、RMSE、R² 及 Adjusted R² 的用途。
- 迴歸假設檢驗的重要性。
- 預測區間的意義。
- 模型限制與未來改進方向。

重要要求：

這份文字在尚未完成 NotebookLM 研究前，只能標示為「NotebookLM 摘要草稿（待研究驗證）」。

請不要虛構 NotebookLM 已經分析過哪些來源，也不要捏造論文、文章或研究結果。

請在網站中預留以下欄位：

- 研究主題。
- 參考來源名稱。
- 來源連結。
- NotebookLM 產生的摘要。
- 學生修訂後的摘要。

另外請提供一份研究紀錄範本，讓我可以將網路上的相關教學文章、統計分析文件或研究論文加入 NotebookLM，再將實際整理出的摘要放回網站及報告。

十一、結果下載

至少提供：

1. 五種特徵選擇方法的比較結果 CSV。
2. 最終模型的評估指標 CSV。
3. 選中特徵清單 CSV。
4. 假設檢驗結果 CSV。
5. 預測值與實際值比較 CSV。
6. 完整分析報告 Markdown。
7. 重要圖表 PNG。

如果時間允許，可以額外提供 PDF 報告。

報告應包含：

- 研究目的。
- 資料來源。
- 資料理解。
- 資料準備。
- 五種特徵選擇方法。
- 模型評估結果。
- 迴歸假設檢驗。
- 預測圖與預測區間。
- CRISP-DM 六階段。
- GPT 輔助內容。
- NotebookLM 摘要。
- 研究限制及結論。

報告內容必須根據實際執行結果產生，不能使用固定的虛構數值。

十二、程式架構與檔案要求

```
├── app.py
├── requirements.txt
├── README.md
├── .gitignore
├── data/
|   └── README.md
├── src/
|   ├── data_loader.py
|   ├── data_preprocessing.py
|   ├── feature_selection.py
|   ├── regression_model.py
|   ├── evaluation.py
|   ├── assumption_tests.py
|   ├── visualization.py
|   └── report_generator.py
└── reports/
└── README.md
```

這只是建議架構，請依照實際程式需求調整。

不要將大型資料集、虛擬環境、快取或敏感資訊直接上傳到 GitHub。

requirements.txt 應列出必要的套件及合理的版本限制。

README.md 必須使用繁體中文，包含：

- 專案介紹。
- 功能說明。
- 資料來源。
- 安裝步驟。
- 如何查看迴歸假設檢驗。
- GitHub 上傳方式。
- Streamlit Community Cloud 部署方式。
- 已知限制。

十三、GitHub 與 Streamlit 部署要求

本專案最後會上傳到 GitHub，並部署至 Streamlit Community Cloud。

請確保：

1. 入口程式為 app.py。
2. requirements.txt 完整。
3. 程式不依賴我電腦上的絕對路徑。
4. 不要求使用者在雲端手動安裝額外的系統套件。
5. 不依賴本機永久儲存的分析結果。
6. 可以在雲端讀取公開 CSV。
7. 使用者可以上傳 CSV。
8. 遇到網路錯誤時提供友善訊息。
9. 遇到不相容欄位時不會讓整個網站直接崩潰。
10. 適當使用 Streamlit 快取，避免重複下載資料。
11. 不將使用者上傳的資料永久保存。
12. 不將 API Key 或其他敏感資訊提交到 GitHub。

請提供 GitHub Repository 的上傳步驟與 Streamlit 部署說明。

如果目前 Repository 已有其他檔案，請先檢查現有結構，再決定建立或修改哪些檔案。

不要直接刪除或覆蓋與本專案無關的既有內容。

1. 避免資料洩漏。
2. 避免在整份資料上先做特徵選擇。
3. 避免目標變數進入特徵矩陣。
4. 避免 ID 欄位被誤認為有意義的連續變數。
5. 避免 One-Hot Encoding 在訓練集與測試集產生不同欄位。
6. 避免特徵數量大於樣本數而造成不穩定的統計估計。
7. 避免將缺失值直接轉換成零而造成偏差。
8. 避免直接刪除所有含缺失值的資料，導致樣本大量流失。
9. 避免使用測試集挑選最佳特徵。
10. 避免把訓練集 R² 當成測試集 R²。
11. 避免將相關性解釋成因果關係。
12. 避免在 Adjusted R² 中錯誤計算特徵數量。
13. 避免把信賴區間當成預測區間。
14. 避免假設檢驗程式因為樣本量、共線性或常數欄位而中斷。
15. 避免使用不存在的欄位名稱。
16. 避免在無法讀取資料時仍顯示看似真實的分析結果。

如果某種特徵選擇方法無法在特定資料集上合理執行，請提供明確的錯誤說明或安全的替代處理，而不是悄悄回傳假結果。

十五、測試與驗收

完成開發後，請實際檢查程式能否執行。

至少確認以下項目：

- ☐ Streamlit 網站可以啟動。
- ☐ Problem 下拉式選單可以切換。
- ☐ 使用者可以上傳 CSV。
- ☐ 使用者可以選擇目標變數。
- ☐ 使用者可以選擇輸入特徵。
- ☐ 五種特徵選擇方法均可執行。
- ☐ 五種方法都能輸出實際模型評估結果。
- ☐ MAE、MSE、RMSE、R² 及 Adjusted R² 計算正確。
- ☐ 五種迴歸假設都有對應的診斷功能。
- ☐ 預測圖正常顯示。
- ☐ 95% 預測區間具有合理的統計依據。
- ☐ 圖表可以下載。
- ☐ CSV 可以下載。
- ☐ 分析報告可以產生。
- ☐ GPT 輔助內容有清楚標示。
- ☐ NotebookLM 摘要有清楚標示，且未經研究驗證的內容會標示為草稿。
- ☐ requirements.txt 完整。
- ☐ README.md 完整。
- ☐ 專案可以部署至 Streamlit Community Cloud。

如果目前環境可以安裝套件並執行程式，請實際安裝必要套件、啟動 Streamlit，並執行至少一組資料的基本測試。

若無法連接外部網路，請改用已知的 Startup 50 範例資料或建立明確標示為測試用途的合成資料，驗證程式流程，但不得將測試資料冒充真實的 Kaggle 汽車資料。

完成後請回報：

1. 建立及修改了哪些檔案。
2. 已實作哪些功能。

7. 哪些功能已經實際測試成功。
8. 哪些功能仍需我手動確認。
9. NotebookLM 摘要需要我補充哪些研究資料。

請先檢查目前 Repository 的實際結構，再開始實作。請直接完成程式開發，不要只回覆一份規劃書。

我另外提醒你 4 個重要細節

這份 Prompt 已經把主要需求整合進去，不過有幾個地方值得你特別注意。

1. 汽車資料集與 Startup 50 的特徵數不同

你的老師要求的是 Kaggle 資料集具有 **超過 13 個特徵**。

- Car Features and MSRP：原始欄位約 16 個，扣除目標變數後，實際輸入特徵會少一個。
- Startup 50：原始資料只有 5 個欄位，其中 4 個是輸入特徵。

所以，Startup 50 雖然適合當作第二種 Problem 的展示範例，**卻不符合超過 13 個輸入特徵的要求**。

建議你在報告中明確區分：

- **主要作業資料集：** Car Features and MSRP。
- **通用性展示資料集：** Startup 50。

如果老師要求兩種 Problem 都必須符合特徵數量限制，就需要再替第二種 Problem 選擇另一份符合條件的資料集。

2. 五種特徵選擇方法要使用同一份測試資料

這點很重要。

如果五種方法使用不同的訓練集或測試集，即使最後 MAE、RMSE、R²，也很難公平比較。

3. 迴歸假設檢驗不是只看 p-value

老師要求驗證五個假設，因此網站不能只放一張檢定結果表。

比較完整的做法是：

假設	建議方法
線性關係	Residuals vs Fitted Plot
誤差獨立性	Durbin-Watson 與資料結構檢查
誤差等變異性	Breusch-Pagan Test、殘差圖
殘差常態性	Q-Q Plot、Shapiro-Wilk Test
無嚴重多重共線性	VIF

尤其汽車資料集可能存在品牌、車款、馬力、售價之間的高度關聯。即使模型的 R² 很高，也不代表所有迴歸假設都成立。

這反而是你報告中可以深入討論的地方。

4. 95% 預測區間是比較容易出錯的部分

一般的 `sklearn.linear_model.LinearRegression` 可以產生預測值，但不會直接提供標準的統計預測區間。

因此，Prompt 特別要求 Agent 使用具有統計依據的方法計算預測區間，而不是直接在預測值上下加減 5% 或 10%。

如果要讓報告更完整，我建議把「實際值與預測值比較圖」、「95% 預測區間圖」及「五項假設檢驗」放在同一個 Evaluation 區塊。 這樣老師可以很快確認你不只是建立模型，還有評估模型的可靠性。

最後，NotebookLM 的部分，你可以先用 Prompt 產生的草稿作為研究方向，再將實際查閱的資料放入

Car Features and MSRP：原始欄位約 16 個，扣除目標變數後，實際輸入特徵會少一個。這是為什麼? 扣除後不是還有15個嗎?

你說得沒錯！**如果原始資料有 16 個欄位，扣除 1 個目標變數後，確實還有 15 個欄位。** 我前面說「實際輸入特徵會少一個」，容易讓人誤以為不只扣除目標變數，這裡我重新說明。

以 Kaggle 的 **Car Features and MSRP** 為例：

1. 原始資料的 16 個欄位

#	欄位名稱	用途
1	Make	汽車品牌
2	Model	車款
3	Year	年份
4	Engine Fuel Type	引擎燃料類型
5	Engine HP	引擎馬力
6	Engine Cylinders	汽缸數
7	Transmission Type	變速箱類型
8	Driven_Wheels	驅動方式
9	Number of Doors	車門數
11	Vehicle Size	車輛尺寸
12	Vehicle Style	車身形式
13	highway MPG	高速公路油耗
14	city mpg	市區油耗
15	Popularity	車款人氣指標
16	MSRP	建議售價

資料來源：Kaggle：Car Features and MSRP

2. 扣除目標變數後，確實有 15 個候選特徵

如果我們要預測汽車的建議售價：

- **目標變數（y）：** `MSRP`
- **候選輸入特徵（X）：** 其餘 15 個欄位

因此：

$$16 - 1 = 15$$

這裡的 15 個是原始資料中可供評估的候選特徵，並不代表最後一定要全部放入模型。

3. 為什麼實際建模時，特徵數量可能改變？

因為原始欄位不一定都適合直接放進多元線性迴歸。

例如：

欄位	建議處理方式	原因
Engine Fuel Type	One-Hot Encoding	類別型資料

Engine Fuel Type	One-Hot Encoding	類別型資料
Engine HP	保留數值	可用來預測價格
Transmission Type	One-Hot Encoding	類別型資料
Market Category	評估是否保留	可能包含多個分類標籤
MSRP	作為目標變數 y	不能同時放入輸入特徵 X

例如，`Make` 原本只占一個欄位，經過 One-Hot Encoding 後，可能轉換成多個欄位。

因此必須區分：

1. **原始候選特徵數：** 15 個。
2. **特徵選擇後的原始特徵數：** 例如選出 10 個。
3. **One-Hot Encoding 後的模型特徵數：** 可能大於或小於原始欄位數，取決於編碼方式與選取的類別。

這三個數字代表不同的概念。

---

4. 那麼，這份資料集符合老師的作業要求嗎？

符合。

老師的要求是 Kaggle 資料集具有超過 13 個特徵。

如果以預測 `MSRP` 為研究目標，這份資料集有 15 個候選輸入特徵，符合要求。

不過，建議你在報告中明確寫出：

> 本研究使用 Kaggle 公開資料集 Car Features and MSRP，原始資料包含 16 個欄位，其中 MSRP 為目標

＋ 問問 ChatGPT 思考

這樣就能清楚說明資料集為什麼符合老師的要求。

另外提醒： 15 個候選特徵不代表最終模型一定使用 15 個特徵。你的作業需要比較五種特徵選擇方法，因此各方法最後保留的特徵數量可能不同，這正是你要分析與比較的重點。

今天 上午11:28

幫我把這個專案我們之間全部的對話轉成pdf讓我下載

處理時間為 13s

已分析

Python

```python
from reportlab.lib.pagesizes import A4
from reportlab.platypus import SimpleDocTemplate, Paragraph, Spacer, PageBreak, KeepTogether
from reportlab.lib.styles import getSampleStyleSheet, ParagraphStyle
from reportlab.lib.enums import TA_CENTER
from reportlab.lib import colors
from reportlab.pdfbase import pdfmetrics
from reportlab.pdfbase.cidfonts import UnicodeCIDFont
from reportlab.lib.units import mm
from xml.sax.saxutils import escape

out = "/mnt/data/AIoTHW2_專題對話整理.pdf"

pdfmetrics.registerFont(UnicodeCIDFont("STSong-Light"))

doc = SimpleDocTemplate(
    out, pagesize=A4,
    rightMargin=20*mm, leftMargin=20*mm,
```

＋ 問問 ChatGPT 思考

```python
styles = getSampleStyleSheet()
styles.add(ParagraphStyle(
    name="CJKTitle", fontName="STSong-Light", fontSize=20, leading=28,
    alignment=TA_CENTER, spaceAfter=14
))
styles.add(ParagraphStyle(
    name="CJKSubtitle", fontName="STSong-Light", fontSize=10, leading=16,
    alignment=TA_CENTER, textColor=colors.HexColor("#555555"), spaceAfter=18
))
styles.add(ParagraphStyle(
    name="CJKHeading", fontName="STSong-Light", fontSize=14, leading=21,
    spaceBefore=12, spaceAfter=8, textColor=colors.HexColor("#17365D")
))
styles.add(ParagraphStyle(
    name="CJKBody", fontName="STSong-Light", fontSize=10, leading=16,
    spaceAfter=7, wordWrap="CJK"
))
styles.add(ParagraphStyle(
    name="CJKSmall", fontName="STSong-Light", fontSize=9, leading=14,
    textColor=colors.HexColor("#666666"), spaceAfter=6, wordWrap="CJK"
))
styles.add(ParagraphStyle(
    name="CJKUser", fontName="STSong-Light", fontSize=10, leading=16,
    leftIndent=8, rightIndent=8, borderPadding=7,
    backColor=colors.HexColor("#EEF4FB"), spaceBefore=4, spaceAfter=8,
    wordWrap="CJK"
))
styles.add(ParagraphStyle(
    name="CJKAssistant", fontName="STSong-Light", fontSize=10, leading=16,
    leftIndent=8, rightIndent=8, borderPadding=7,
    backColor=colors.HexColor("#F5F5F5"), spaceBefore=4, spaceAfter=8,
    wordWrap="CJK"
))

story = []
story.append(Paragraph("AIoTHW2 專題對話整理", styles["CJKTitle"]))
```

＋ 問問 ChatGPT 思考

```python
    "不是整個專案所有聊天室的完整逐字匯出。為避免誤認為完整原始紀錄，以下將問題與答覆整理成可閱讀的紀錄。",
    styles["CJKBody"]))
story.append(Spacer(1, 5))

def add_turn(label, text, style):
    story.append(Paragraph(f"<b>{escape(label)}</b>", styles["CJKHeading"] if label.startswith("使用者") else styl
    for block in text.split("\n\n"):
        story.append(Paragraph(escape(block).replace("\n", "<br/>"), style))

add_turn("使用者問題 1：尋找符合條件的 Kaggle 汽車資料集",
"""在 Kaggle 上的多元線性迴歸問題，跟汽車有關的內容，是否有特徵數量大於 13 且小於 40 的項目?""", styles["CJKUser"])

add_turn("助理答覆 1：候選資料集與建議",
"""建議優先考慮 Car Features and MSRP（Kaggle：CooperUnion/cardataset）。此資料集約有 11,914 筆資料、16 個原始欄位，以
story.append(Paragraph("資料集連結：<link href='https://www.kaggle.com/datasets/CooperUnion/cardataset' color='blu

add_turn("使用者問題 2：作業需求與 VS Code Agent Prompt",
"""使用者提供作業要求，包含：
1. 使用 Kaggle 公開資料集，特徵數量需大於 13。
2. 建立線性迴歸預測模型，進行特徵選擇與模型評估。
3. 結果需呈現預測圖，並包含信賴區間或預測區間。
4. 報告須涵蓋 CRISP-DM 六階段：Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation、D
5. 需自行將 ChatGPT 對話匯出為 PDF。
6. 使用 NotebookLM 研究網路上的同主題解法，並在報告放入 100 字以上摘要，清楚標示「GPT 輔助內容」與「NotebookLM 摘要」。
7. 加分項目：下拉選單呈現兩種問題類型；允許輸入任意 CSV 資料集網址，並以 Startup 50 CSV 作為示例。
8. 希望透過 VS Code Agent 建立專案，之後上傳 GitHub 並部署到 Streamlit。""", styles["CJKUser"])

add_turn("助理答覆 2：完整專案規劃重點",
"""先前提供的 Agent Prompt 規劃了以下功能與架構：

一、Streamlit 介面
- Problem 1：Car Price Prediction，使用 Car Features and MSRP。
- Problem 2：Custom Dataset Regression，允許輸入 CSV URL 或上傳 CSV，並提供 Startup 50 作為通用資料集示例。
- 透過下拉選單切換問題類型。

二、五種特徵選擇方法
- Pearson Correlation
```

＋ 問問 ChatGPT 思考

```python
- LassoCV（用於特徵選擇，最終預測模型仍使用 Linear Regression）

三、模型評估
- 使用一致的訓練 / 測試資料切分，比較五種特徵選擇方法。
- 指標包括 MAE、MSE、RMSE、R²、Adjusted R²。
- 產生預測結果圖與 95% 預測區間；建議使用 statsmodels OLS 的 get_prediction().summary_frame() 等正確方法，不應自行捏造

四、迴歸假設檢查
- 線性關係、誤差獨立性、同質變異性、殘差常態性、嚴重多重共線性。
- 視覺化或檢定包含 Residuals vs Fitted、Durbin-Watson、Breusch-Pagan、Shapiro-Wilk、Q-Q plot、VIF。

五、CRISP-DM 與交付物
- 報告涵蓋六個階段。
- 提供「GPT 輔助內容」及「NotebookLM 摘要」區塊；NotebookLM 摘要需在實際完成資料蒐集後再撰寫，不應將草稿冒充成已完成的研究
- 專案採模組化結構，例如 app.py、src/、requirements.txt、README.md、data/、reports/。
- 加入 GitHub 與 Streamlit Community Cloud 部署說明及基本測試。
- Startup 50 僅有約 4 個預測特徵，不符合主要資料集需大於 13 個特徵的條件，因此只適合作為「自訂 CSV 泛用功能」示範，不能取

add_turn("使用者問題 3：為什麼 16 個欄位扣除目標變數後會少一個？",
"""Car Features and MSRP：原始欄位約 16 個，扣除目標變數後，實際輸入特徵會少一個。這是為什麼? 扣除後不是還有 15 個嗎?""",

add_turn("助理答覆 3：更正欄位數量",
"""使用者的理解是正確的：原始資料有 16 個欄位，若其中 MSRP 是目標變數 y，扣除後就有 15 個候選輸入特徵 X。

15 個候選輸入欄位為：
1. Make
2. Model
3. Year
4. Engine Fuel Type
5. Engine HP
6. Engine Cylinders
7. Transmission Type
8. Driven_Wheels
9. Number of Doors
10. Market Category
11. Vehicle Size
12. Vehicle Style
13. highway MPG
```

＋ 問問 ChatGPT 思考

```python
第 16 個欄位 MSRP 是預測目標，不當作輸入特徵。""", styles["CJKAssistant"])

add_turn("助理答覆 3：為何模型實際使用欄位可能不同",
"""需要區分三個概念：
- 原始候選特徵：15 個原始欄位（不含 MSRP）。
- 特徵選擇後保留的欄位：依方法與設定可能少於 15 個。
- 類別編碼後的模型矩陣欄位：Make、Model、Transmission Type 等類別欄位經 One-Hot Encoding 後，可能展開成許多數值欄位，因

因此，報告可寫：
「本研究使用 Kaggle 公開資料集 Car Features and MSRP，原始資料包含 16 個欄位，其中 MSRP 為目標變數，其餘 15 個欄位作為候

story.append(Spacer(1, 8))
story.append(Paragraph("後續提醒", styles["CJKHeading"]))
story.append(Paragraph(
    "此整理檔包含目前可取得的本專題核心討論，但不是 ChatGPT 帳號中所有相關聊天室的完整逐字稿。"
    "若作業要求完整對話紀錄，建議再透過 ChatGPT 的資料匯出功能匯出帳號資料，或將其他聊天室的對話逐一提供後合併。",
    styles["CJKSmall"]))

def footer(canvas, doc):
    canvas.saveState()
    canvas.setFont("STSong-Light", 8)
    canvas.setFillColor(colors.HexColor("#777777"))
    canvas.drawString(20*mm, 10*mm, "AIoTHW2 專題對話整理 | 非完整帳號逐字稿")
    canvas.drawRightString(A4[0] - 20*mm, 10*mm, f"第 {doc.page} 頁")
    canvas.restoreState()

doc.build(story, onFirstPage=footer, onLaterPages=footer)
print(out)
```

STDOUT/STDERR

```
/mnt/data/AIoTHW2_專題對話整理.pdf
```

已經幫你整理並產生 PDF，可以直接下載。

下載 AIoTHW2 專題對話整理.pdf

＋ 問問 ChatGPT 思考

1. **資料集選擇**：Car Features and MSRP，以及特徵數量的要求。
2. **作業需求整理**：CRISP-DM 六階段、NotebookLM 摘要、GPT 輔助內容等。
3. **VS Code Agent 專案規劃**：Streamlit 網站、五種特徵選擇方法、模型評估與部署。
4. **欄位數量說明**：為什麼原始資料有 16 個欄位，扣除 MSRP 後會剩下 15 個候選輸入特徵。
5. **後續作業提醒**：GitHub、Streamlit 部署及報告製作。

請特別注意： 這份 PDF 是依照目前可取得的專題對話內容整理而成，並非此專案中所有聊天室的完整逐字稿。如果你要交給老師作為「ChatGPT 對話紀錄」，而老師要求完整對話，建議再透過 ChatGPT 的資料匯出功能取得完整紀錄。

AIoTHW2_專題對話整理.pdf
PDF

ChatGPT 可能會出錯。請查證重要資訊。

＋ 問問 ChatGPT 思考